Discussão de Implementação do Algoritmo MINAS

Luís Henrique Puhl de Souza
Orientador: Prof. Dr. Hermes Senger

24 de agosto de 2020

Universidade Federal de São Carlos
Centro de Ciências Exatas e de Tecnologia
Departamento de Computação
Programa de Pós-Graduação em Ciência da Computação

Introdução

Introdução

Este documento tem por objetivo apresentar o algoritmo Minas e suas implementações guiando discussões sobre os detalhes e decisões nas implementações.

Recorda-se que o contexto dessa discussão é o mesmo do sistema M-FOG:

- Um sistema para detecção de intrusão em Redes IoT implementando em névoa;
- A hipótese do trabalho é que o algoritmo MINAS pode ser distribuído em nós de nuvem e névoa reduzindo a latência e com pouco comprometimento na qualidade de detecção.
- Fundamentos
  - Métodos Detecção de Novidade;
  - Ambientes de computação Distribuída;
  - Plataformas de processamento distribuído de fluxos.

Algoritmo MINAS

- Modelo de aprendizado Offline-Online;
- Transformação dos dados analisados para o espaço $\mathbb{R}^d$;
- Modelo de classificação com Clusters;
- Função de classificação baseada em distância euclideana;
- Algoritmo de agrupamento para identificação de novos padrões;
- Classificação de novos padrões entre recorrência, extensão e novidade;

Proposta

Proposta da Pesquisa

- Implementar a distribuição do algoritmo MINAS em nuvem e névoa conforme arquitetura IDSA-IoT;
- Paralelizar o método de classificação do algoritmo MINAS.

Metodologia

- Plataforma de processamento distribuído;
- Estratégias de implementação da arquitetura IDSA-IoT;
- Experimentação com a distribuição do algoritmo MINAS em ambientes;
- Métricas de qualidade de classificação para validação da implementação;
- Métricas de escalabilidade.

Proposta

O sistema M-FOG é dividido em 5 módulos subdivididos em 2 grupos.

Módulos principais implementam o algoritmo MINAS

- módulo treinamento (Training Module);
- módulo classificador (Classification Module);
- módulo detector de novidades (Novelty Detection Module).

Módulos auxiliares, utilizados para avaliação

- módulo auxiliar source (fonte);
- módulo auxiliar sink (sorvedouro, consumidor final).

Proposta

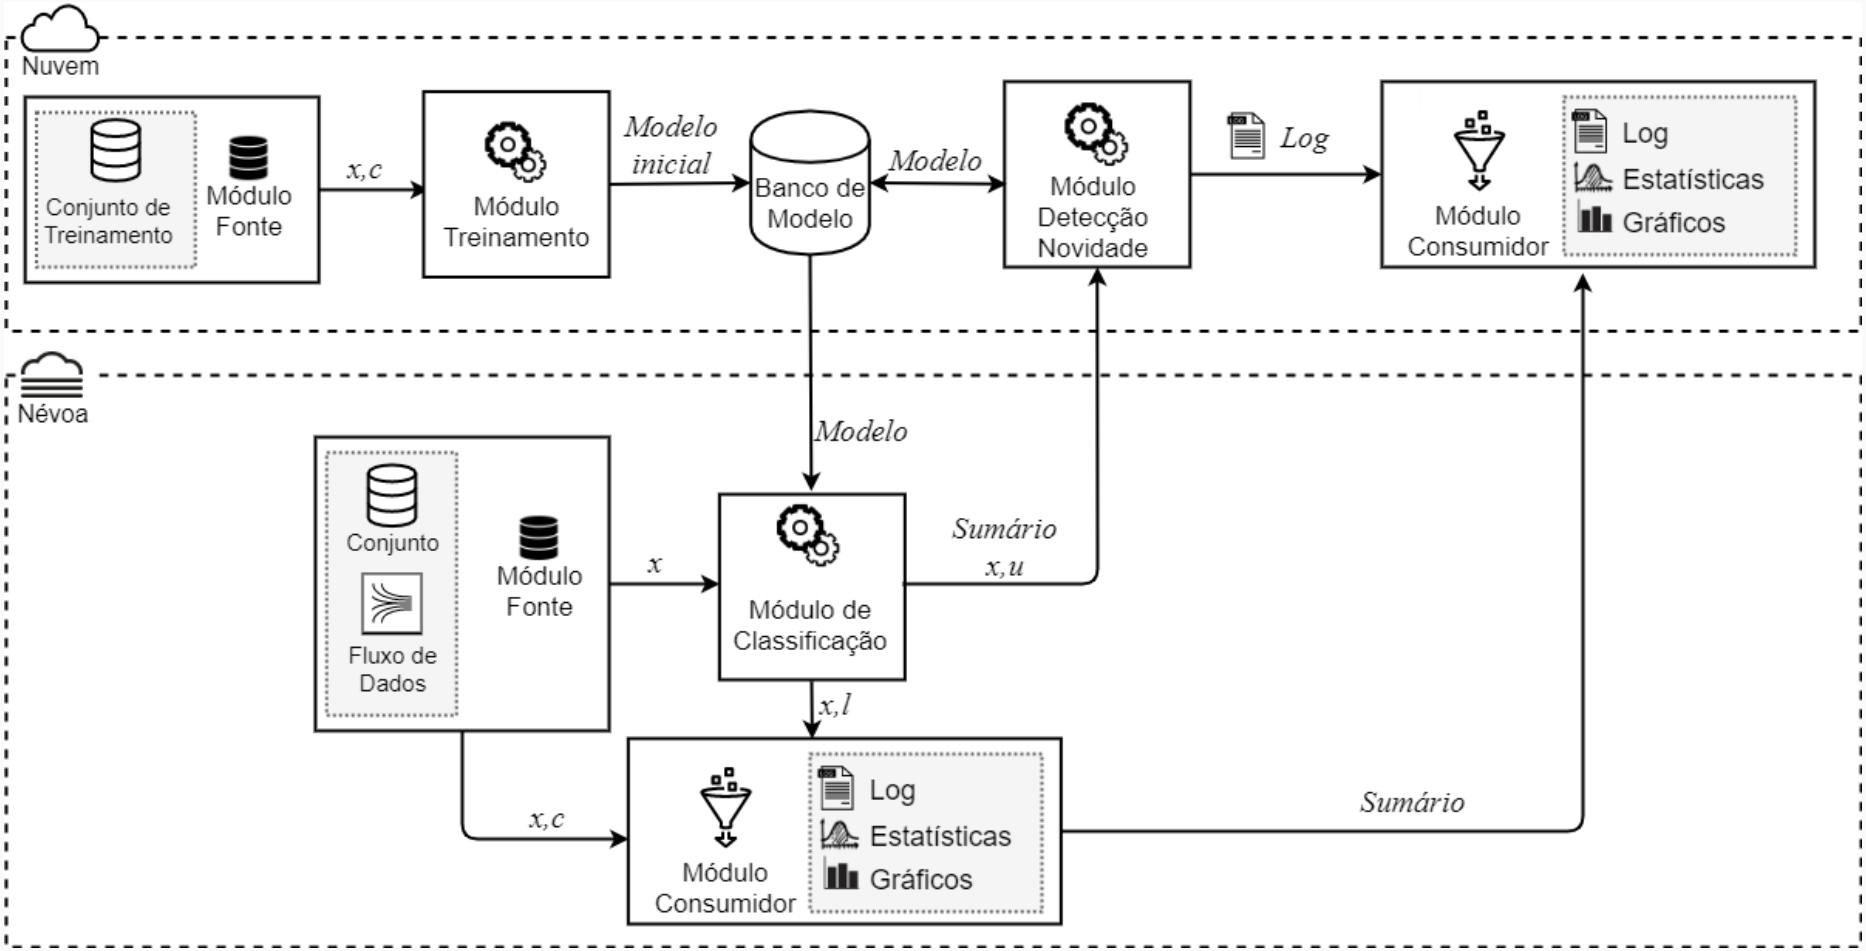

Figura 1: Arquitetura e fluxos de dados do sistema M-FOG.

Método de Avaliação

Métricas e Ambientes

- Métricas de qualidade de classificação:
  - Avaliação do fluxo de saída do classificador;
  - Uso de uma matriz de confusão ou erro;
  - Taxa de desconhecidos;
  - Macro F-score;

$$\mathrm{E}_n = \begin{pmatrix} e_{1,1} & e_{1,2} & \cdots & e_{1,J} \\ e_{2,1} & e_{2,2} & \cdots & e_{2,J} \\ \vdots & \vdots & \ddots & \vdots \\ e_{M,1} & e_{M,2} & \cdots & e_{M,J} \end{pmatrix}$$

$$UnkR_n = \frac{1}{M} \sum_{i=1}^{M} \frac{\#Unk_i}{\#ExC_i}$$

$$\mathrm{Fscore1}_n = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$

Método de Avaliação

Métricas e Ambientes

- Métricas de escalabilidade:
  - Número e tipo de processadores;
  - Uso de memória;
  - Tempo de processamento;
  - Taxa de eventos;
  - Latência entre a produção e classificação.
- Ambientes de teste:
  - Computador Pessoal (para desenvolvimento);
  - Nuvem UFSCar;
  - Nevoa composta de SBC (Sigle Board Computer) ARM 4 núcleos;

Resultados Preliminares

Resultados Preliminares

Primeira Implementação com Python e Apache Kafka

- Python é acessível e fornece bibliotecas diversas;
- Apache Kafka é um sistema de mensagens distribuído;
  - Interface de programação com cliente produtor e consumidor;
  - Mensagens organizadas em tópicos que são distribuídos em partições;
- A hipótese de que a carga seria distribuída entre os consumidores, uma vez que o consumidor pode selecionar uma partição para leitura;
- Em experimento com um produtor, 8 partições e 8 consumidores, observou-se que um consumidor processava a maior parte das mensagens, poucos consumidores recebiam algumas mensagens e a maioria dos consumidores não recebia mensagem alguma.

Resultados Preliminares

Segunda Implementação com Apache Flink

- Implementação escrita em Scala ou Java;
- Processamento de fluxos Stateful;
- Falta de bibliotecas que distribuam algoritmos base como K-means;
- Ambiente de execução (Flink Cluster) consome mais memória do que disponível no hardware;
- Tempo de execução não foi melhor que a implementação original mesmo sem o trecho de detecção de novidades;

Resultados Preliminares

Terceira Implementação com OpenMPI

- Implementação escrita em C;
- Versão serial e versão paralela e distribuída com MPI;
- Reimplementação de algoritmos base como K-means;
- Sistema M-FOG em desenvolvimento, atualmente na fase de validação através das métricas de qualidade de classificação.
  - Diferença entre os modelos iniciais gerados pelo algoritmo K-means;re
  - Diferença na matriz de confusão resultante da avaliação dos fluxos de saída;

Resultados Preliminares

Terceira Implementação com OpenMPI

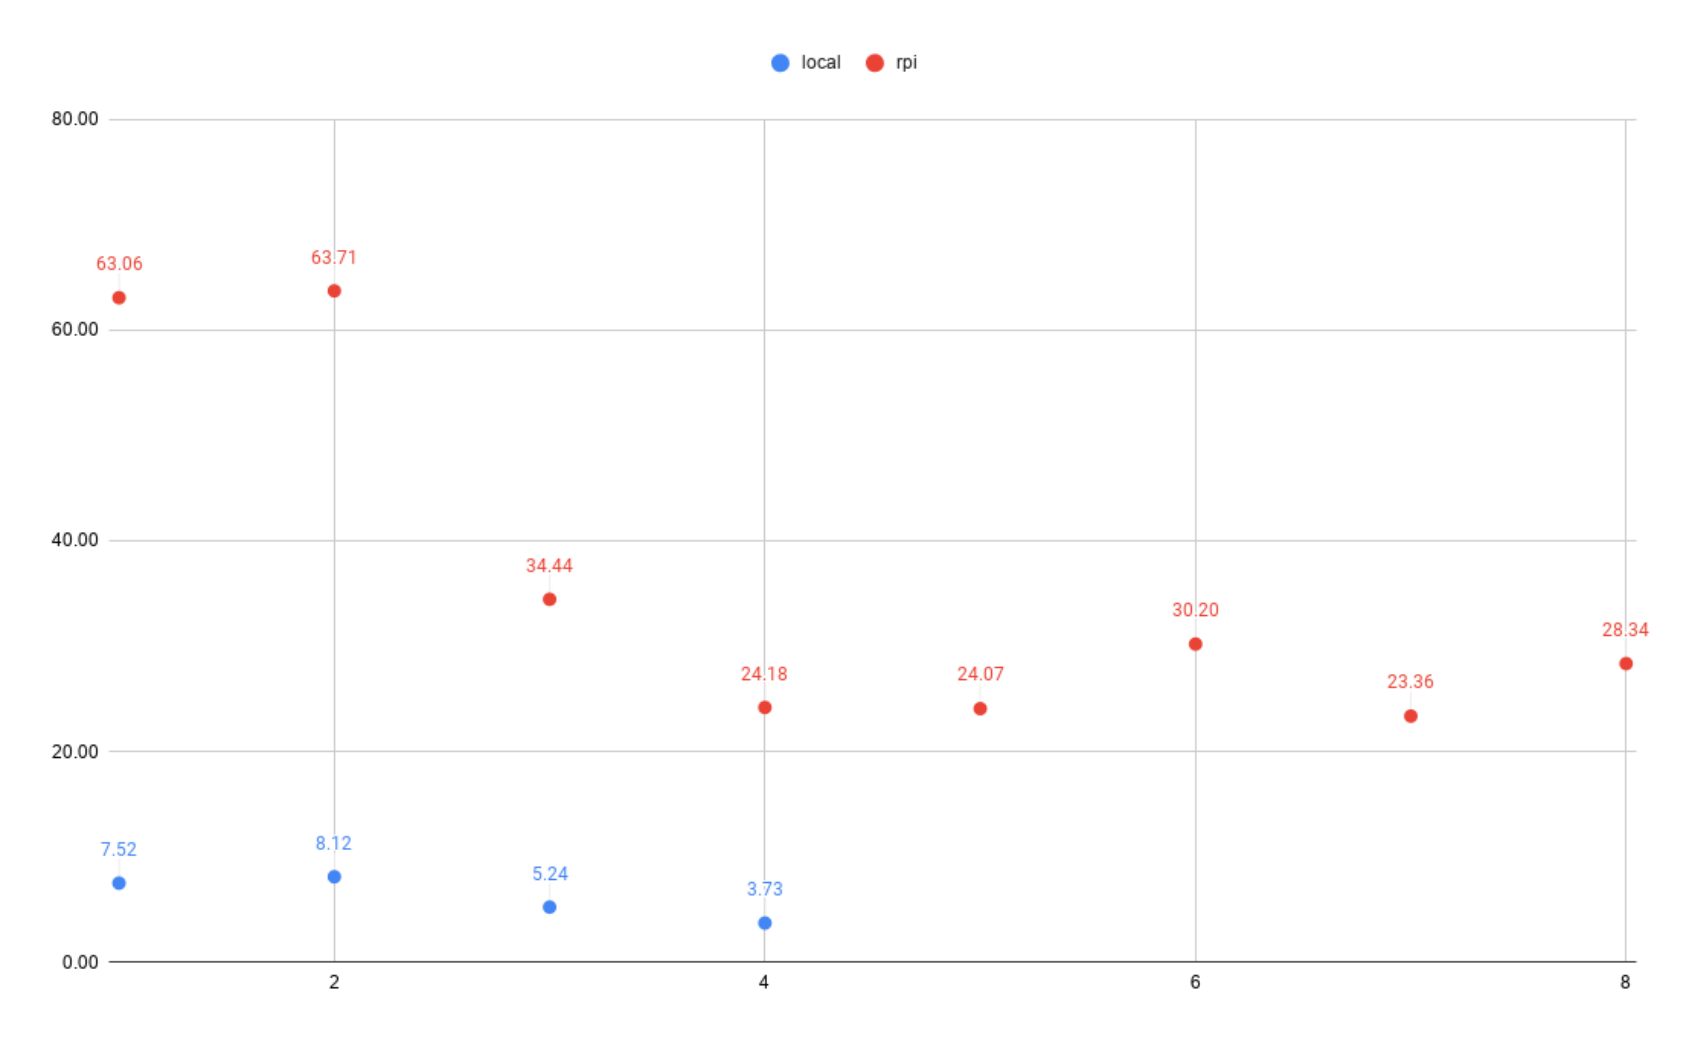

Resultados Preliminares

Desafios Atuais

- ~~Diferença entre `double` e `float`;~~
- ~~Formato do fluxo de saída;~~
- ~~Tratamento de exemplos com etiqueta *desconhecido* utilizados para atualização do modelo;~~
- ~~Diferença entre incluir ou não a borda do cluster;~~
- ~~Definição de raio;~~
- Distribuição e paralelização para minimização de latência entre novo item no fluxo e sua classificação;
- Detecção de novidades e manutenção de modelo em ambiente distribuído.

Notas de Implementação

Algoritmo MINAS

Outras abordagens e implementações

- FuzzyND por Da Silva 2018;
- Minas-LC e Minas-BR por Costa 2019;
- Implementação em Java por Douglas (douglas.m.cavalcanti@gmail.com) em Jul 2 09:37:42 2019
- Implementação em Python por Vitor Sexto Bernardes (vitorsb@gmail.com) em May 11 23:51:09 2020

Implementação referência

Parâmetros

```
class br.ufu.noveltydetection.minas.MinasOg with
        filenameOffline = datasets/training.csv
        filenameOnline = datasets/test.csv

        outputDirectory = out/minas-og//2020-07-20T12-18-21.758/
        algClusteringOff = kmeans
        algClusteringOnl = kmeans

        threshold = 2.0
        flagEvaluationType = 1
        thresholdForgettingPast = 10000
        numMicro = 100
        flagMicroClusters = true

        minExCluster = 20
        validationCriterion = dec

        skipNd = false
```

Nova Implementação

Parâmetros

```
params->kParam = 100;
params->dimension = 22;
params->noveltyThreshold = 2;
params->minExCluster = 20;
params->maxUnkSize = params->kParam * params->minExCluster;
params->thresholdForgettingPast = 10000;
```

Implementação Referência e Avaliação de Referência

A implementação de referência gera um arquivo (fluxo) de saída e arquivo de matriz de confusão.

Além disso é gerado um gráfico das métricas (Err, FNew, Mnew) calculadas para cada item do fluxo.

Implementação Referência e Avaliação de Referência

Reference Output Stream, Reference Evaluation

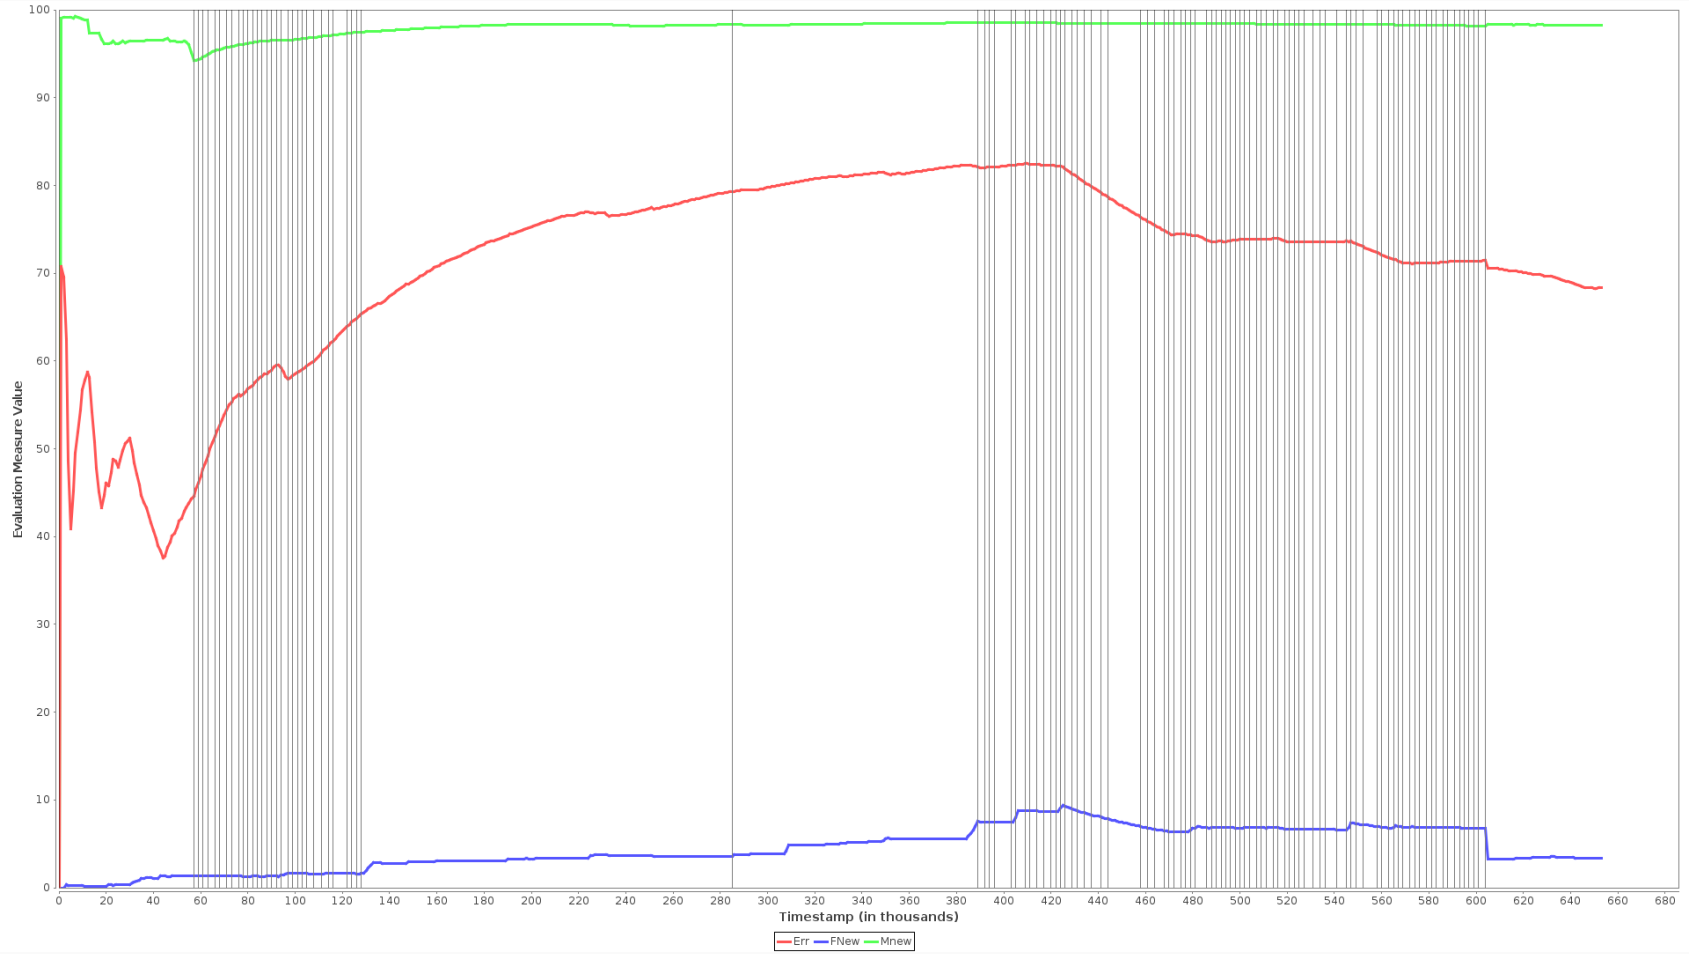

Implementação Referência e Avaliação de Referência

Matriz de confusão gerada pela Implementação referência

	C N	C A
C N	199263	439530
N 1	0	123
N 2	79	145
N 3	44	368
N 4	0	8
N 5	0	52
N 6	0	165
N 7	229	1
N 8	181	1046
N 9	826	2133
N 10	5088	3467
N 11	289	71
N 12	0	26
Unk	279	44

Aplicando a técnica de associação de etiquetas à classes descrita em **??**), tem-se que 208935 itens foram etiquetados corretamente (true positive). Portanto a *taxa de acerto* é $208935/653457 = 0.319737948$.

Implementação de Referência e Nova Avaliação

O fluxo de saída da implementação de referência pode ser consumido pelo módulo de avaliação da nova implementação (sistema M-FOG).

Implementação de Referência e Nova Avaliação

Fluxo de saída Original, Grafico da Nova Avaliação

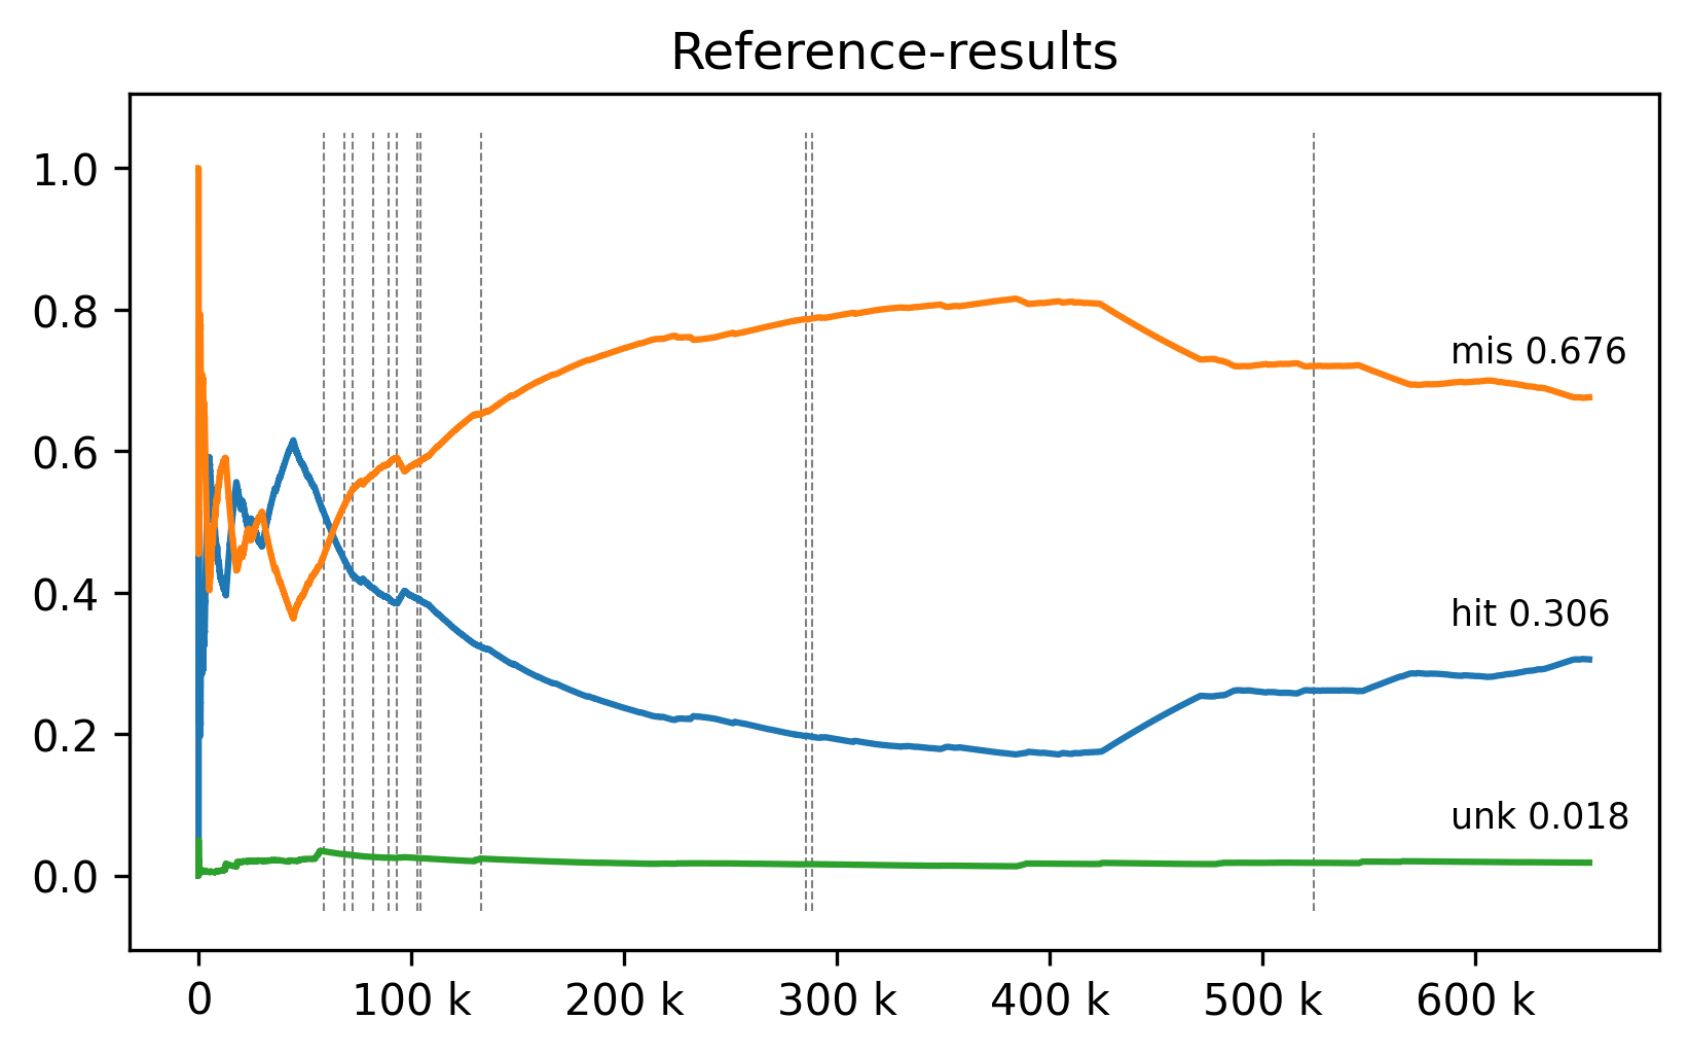

Implementação de Referência e Nova Avaliação

Matriz de confusão e avaliação, Fluxo de saída Original

Classes (act) Labels (pred)	A	N
-	3774	8206
1	123	0
10	2489	4066
11	71	289
12	26	0
2	145	79
3	368	44
4	8	0
5	52	0
6	165	0
7	1	229
8	1046	181
9	161	154
N	438750	193030

Métrica	Valor	
Total examples	653457	
Total matches	653457	
Hits	199708	0.30561766
Misses	441769	0.67604907
Unknowns	11980	0.01833326
Unk. reprocessed	0	0.00000000

Implementação de Referência e Nova Avaliação

Além do consumo do fluxo com formato original, foi adicionado à implementação de referência o passo de reprocessamento e saída no novo formato.

Implementação de Referência e Nova Avaliação

New Format, Reference Output Stream, Evaluation

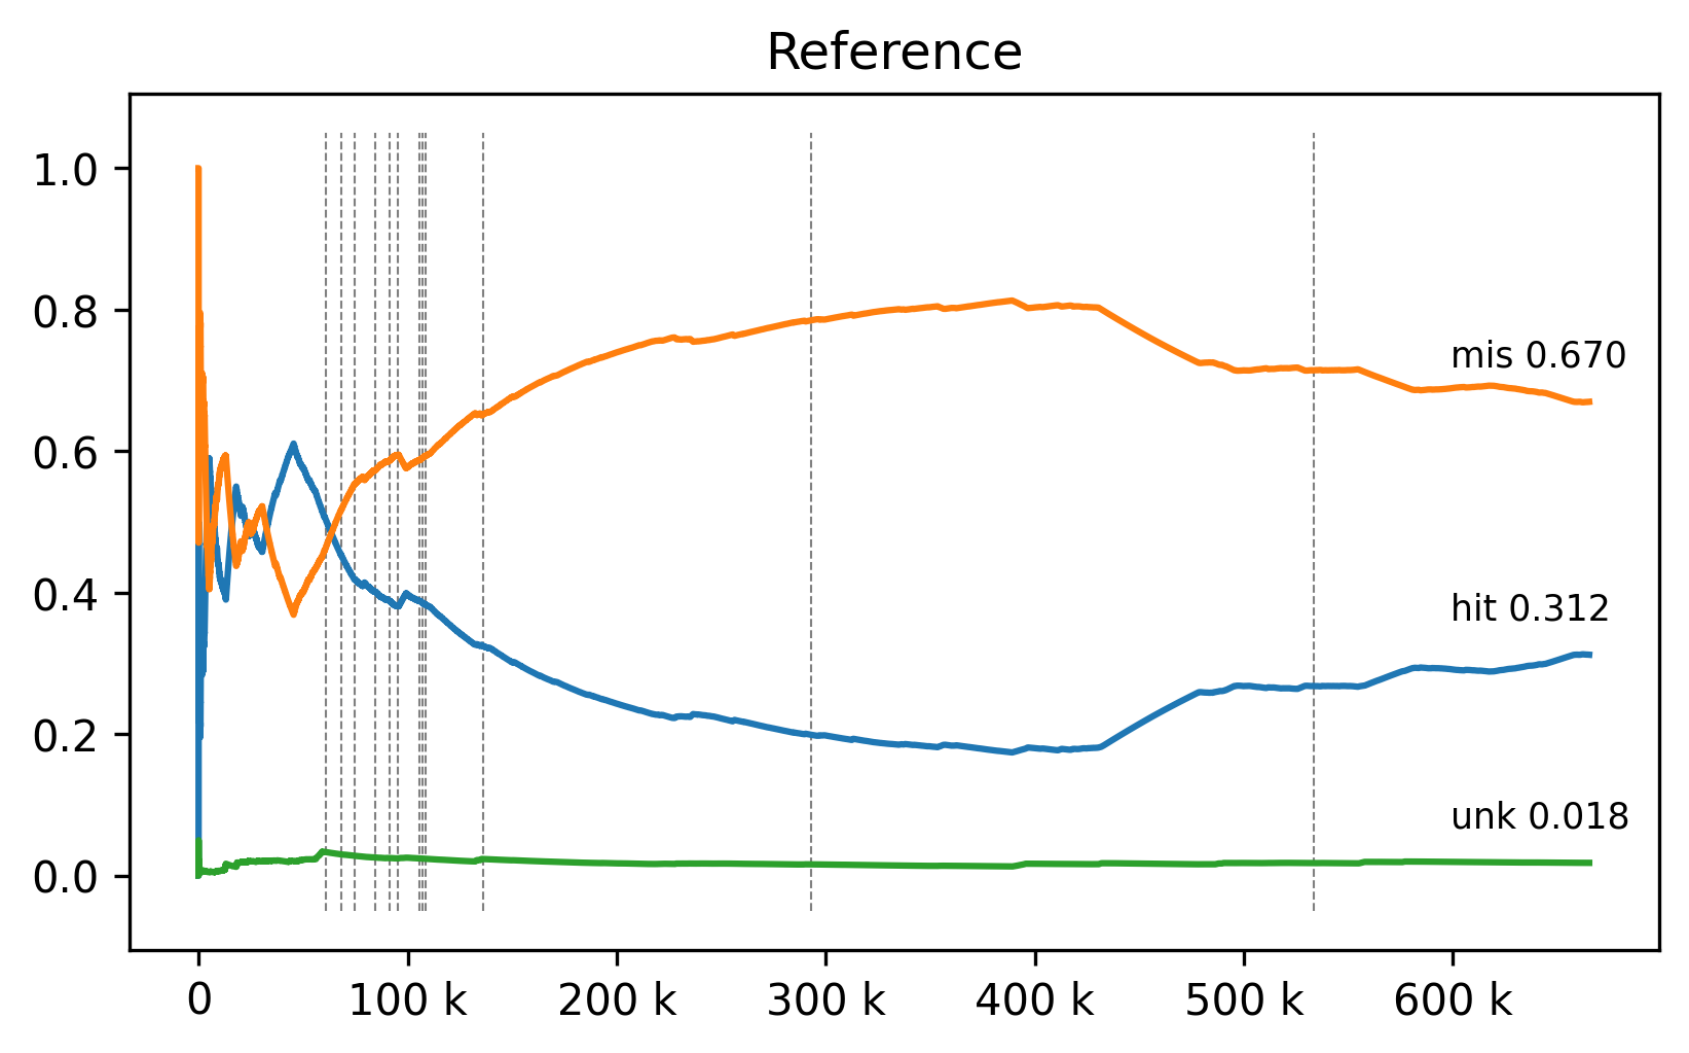

Implementação referência

Matriz de confusão e avaliação, Novo formato Fluxo de saída

Classes (act) Labels (pred)	A	N
-	3774	8206
1	123	0
10	3520	5130
11	71	289
12	26	0
2	152	82
3	368	44
4	8	0
5	82	1
6	165	0
7	8	396
8	1054	183
9	161	154
N	441395	199715

Métrica	Valor	
Total examples	653457	
Total matches	665107	
Hits	207669	0.31223397
Misses	445458	0.66975389
Unknowns	11980	0.01801214
Unk. reprocessed	11650	0.97245409

Implementação Baseline e Nova Avaliação

Implementação serial, não distribuída, do algorítmo MINAS em C que serve de base (biblioteca) para a implementação sistema M-FOG e para cálculo de speed-up.

Implementação Baseline e Nova Avaliação

Baseline Output Stream, Evaluation

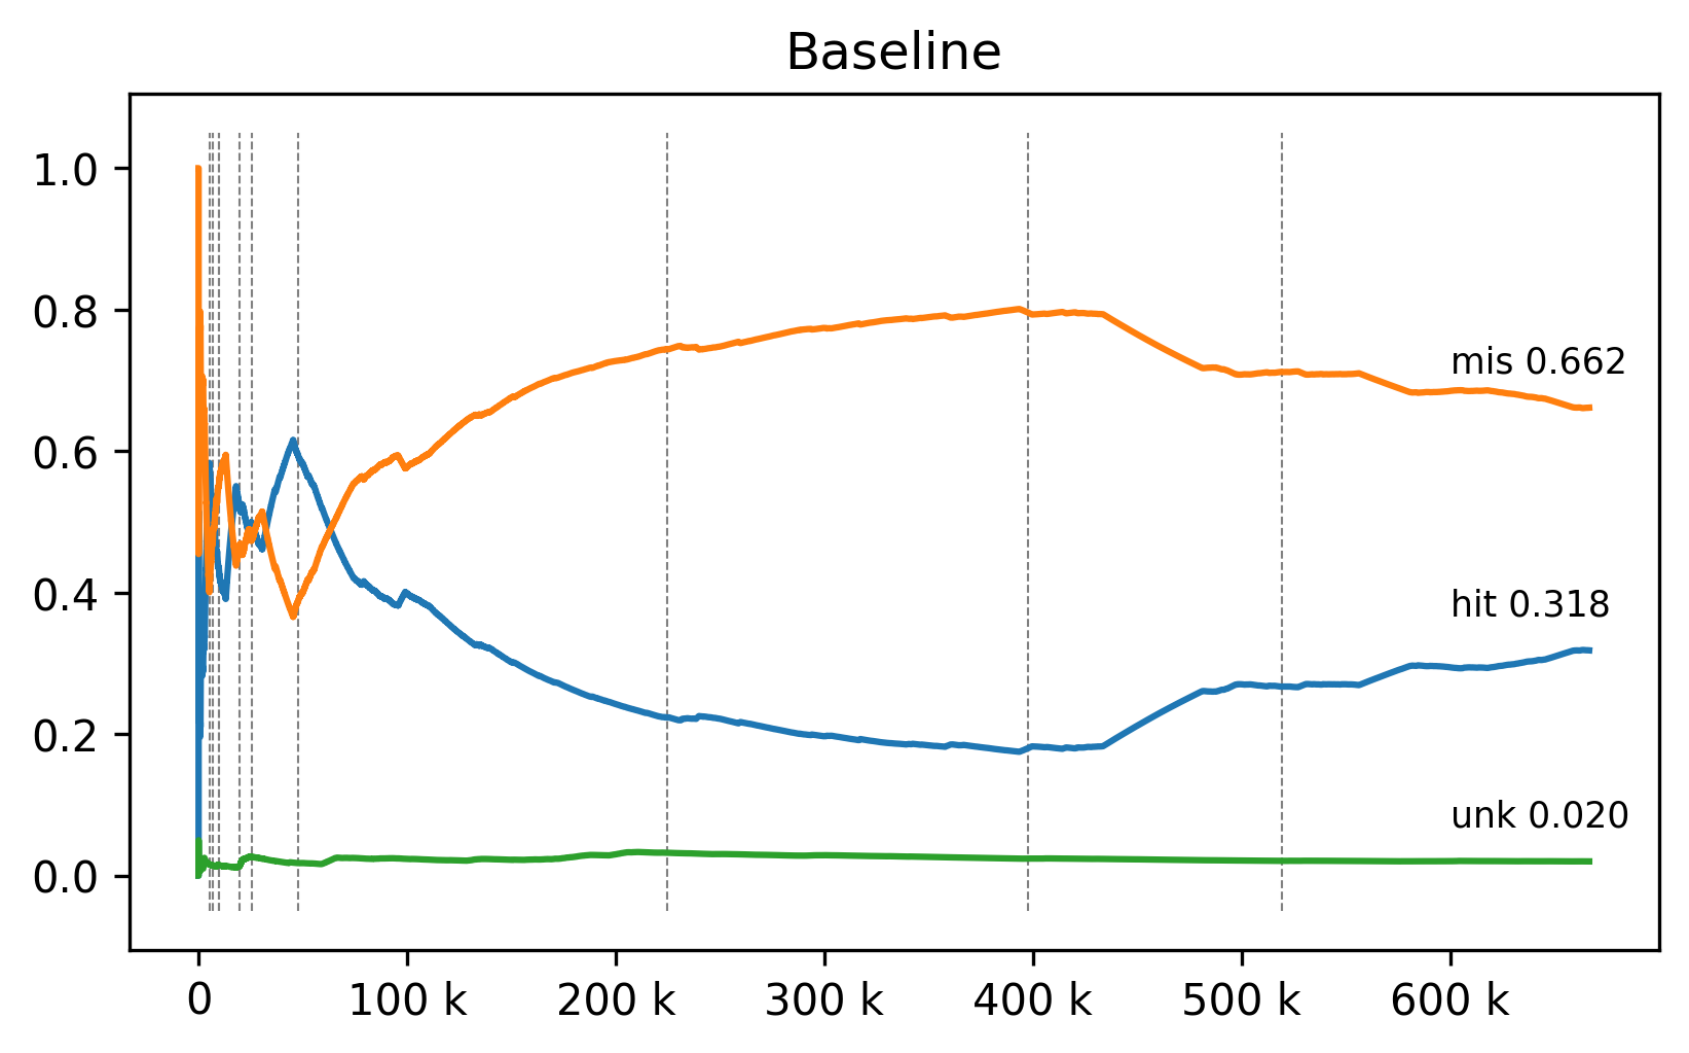

Implementação Baseline e Nova Avaliação

Matriz de confusão e avaliação, Novo formato Fluxo de saída

Classes (act) Labels (pred)	A	N
-	10263	3122
0	1798	48
1	315	0
2	1098	156
3	0	318
4	1510	20
5	2	53
6	1560	2
7	31	0
8	31	3
9	58	3
N	440712	205476

Métrica	Valor	
Total examples	653457	
Total matches	666579	
Hits	212248	0.31841387
Misses	440946	0.66150599
Unknowns	13385	0.02008014
Unk. reprocessed	13122	0.98035114

```
k=100; radiusF = 0.25; minExamp
noveltyF = 1.4
```

Implementação Referência versus Baseline

Matriz de confusão e avaliação na Referência versus Avaliação sistema M-FOG

Nota-se que como o novo método de avaliação utiliza o fluxo de saída do algoritmo, as métricas tem valores semelhantes mas não idênticos.

Em especial, a soma de todas as células da matriz de confusão na referência é de 653457 (contagem de itens no fluxo de entrada) e na avaliação atual (sistema M-FOG) é de 665107 (contagem de itens no fluxo de saída).

O mesmo acontece no número de acertos: Na referência 208935 com taxa 0.319737948 e na avaliação atual 207669 com taxa 0.31223397.

Notas de Implementação

Algoritmo MINAS vs Implementação referência

- Definição de raio: desvio padrão das distâncias versus distancia máxima;
- Atualização do micro-cluster limita-se à atualização do atributo `T`;
- Remoção de exemplos na implementação de referência é feita somente para o algoritmo *CluStream*;
- Inclusão de borda: algoritmo inclui ($<=$), referência não inclui ($<$);

Notas de Implementação

Algoritmo MINAS vs Nova Implementação

- Seguiu-se as mesmas divergências anteriores para comparação dos resultados com a implementação referência;
- Inclusão da borda;
- Comportamento do mecânismo de *sleep-model* não está definido, portanto não está ativo;
- Processo de clusterização é limitado ao algoritmo *K-Means*. Algoritmo *CluStream* não está implementado;

Obrigado!

Referências i